

Feminismus, Algorithmen, Gender-Data-Gap und was das alles mit Bibliotheks- und Informationswissenschaft zu tun hat

Sara Juen

Kurzfassung: In den letzten Jahren gab es vermehrt Berichte über unethisches Handeln in Technologiekonzernen und Hinweise darauf, dass Algorithmen nicht neutral handeln, sondern gesellschaftlich bestehende Ungerechtigkeiten weiterführen oder diese sogar verschärfen. Der vorliegende Artikel gibt einen Einblick in diese Thematik und zeigt auf, warum dieses Thema für die Bibliotheks- und Informationswissenschaft relevant ist.

Abstract: In recent years, there have been increasing reports about unethical actions in technology corporations and indications that algorithms do not act neutrally, but rather continue existing social injustices or even intensify them. This article provides insight into this issue and shows why this topic is relevant to library and information science.

Wir sitzen an unserem Computer oder Smartphone und scrollen durch vorgeschlagene Angebote. Wir hören uns Musik an, die uns, basierend auf unserer Playlist, empfohlen wird und lassen uns von einem Navigationssystem durch den Großstadtdschungel führen. Wenn wir eine Auskunft zu unserer Kreditwürdigkeit machen müssen, geben wir einen Score weiter, der von einem Algorithmus berechnet wurde. Mittlerweile ist es für uns normal, dass wir von maschinell lernenden Algorithmen (auch „schwache Künstliche Intelligenz“ genannt) umgeben sind. Sie schlagen uns Produkte und Dienstleistungen vor, die wir eventuell kaufen wollen, die Sozialen Medien buhlen um unsere Aufmerksamkeit und Bildschirmzeit und Alexa reagiert auf unsere Anfragen. Und das alles basierend auf Daten, die über uns gesammelt wurden oder aus abgeleiteten Daten von Anderen. Im Allgemeinen wird angenommen, dass datenbasierte Software neutral und unvoreingenommen ist und somit gewisse Entscheidungen „besser“ treffen kann als der Mensch.

Seit einigen Jahren gibt es einen stetig größer werdenden Diskurs und zunehmend Untersuchungen darüber, ob diese Annahme der Neutralität tatsächlich zutrifft. Mittlerweile wurde die Vermutung, dass Algorithmen neutrale(re) Entscheidungen treffen, vielfach widerlegt (vgl. O’Neil 2017; Zweig 2019). Tatsächlich verstärken datenbasierte Entscheidungssysteme bestehende Diskriminierungen und Benachteiligungen eher noch als sie zu verringern (vgl. Zweig 2019, S. 211). Funktionstüchtige Entscheidungssysteme müssen nicht nur programmiert werden, sondern auch trainiert. Damit ein Algorithmus arbeiten kann, braucht er eine enorme Menge an Trainingsdaten, anhand derer er „lernt“ Entscheidungen zu treffen. Die Trainingsdaten,

die der Algorithmus bekommt, sind bereits vorhandene Daten aus der Vergangenheit. Diese Datengrundlage kann schon an sich problematisch sein, da die bereits bestehenden Daten sehr wahrscheinlich die Wertvorstellungen und Diskriminierungen repräsentieren, die in der Gesellschaft herrschen, in der sie erhoben wurden. So werden bereits vorbelastete Daten durch den Algorithmus zu vermeintlich neutralen Datenströmen. In Wirklichkeit werden aber die eingebetteten Benachteiligungen reproduziert und verstärkt. Das folgende Beispiel aus den USA macht diesen Prozess deutlich.

In den USA wird ein datenbasiertes Bewertungssystem bei Strafverfahren verwendet. Dieses soll den Richter_innen dabei helfen, anhand eines berechneten Risiko-Scores für die angeklagte Person die angemessene Strafe zu fällen. Diesem algorithmischen Bewertungssystem liegen Daten zugrunde, die seit 1995 anhand eines Fragebogens erhoben werden. Der Fragebogen, der von den festgenommenen Personen selbst ausgefüllt werden muss, stellt allgemeine Fragen zu der Person, aber auch sehr persönliche. Fragen, wie oft die angeklagte Person schon mit der Polizei zu tun hatte oder in welchem Alter das erste Mal Kontakt mit der Polizei bestand, können schon eine Diskriminierung auslösen, bedenkt man dabei, dass BIPOC (Black, Indigenous and People of Color) sehr viel häufiger von der Polizei angehalten und kontrolliert werden als weiße Personen. Des Weiteren enthält der Fragebogen auch Fragen zum persönlichen Leben, zum Beispiel wie man aufgewachsen ist, wie die Familienkonstellation war und Fragen zu Freunden. Fragen, die bei einer Straftat keine Rolle spielen sollten, sich aber negativ auf die Bewertung auswirken können. Mehrere Studien haben bewiesen, dass dieses System BIPOC benachteiligt und sie höhere Strafen bekommen als weiße Menschen mit vergleichbaren Vergehen (vgl. O'Neil 2017, S. 25 ff).

In dem Dokumentarfilm „Coded Bias“ von Shalini Kantayya erzählt die MIT Computerwissenschaftlerin Joy Buolamwini, wie ihr während der Arbeit im Computer Lab aufgefallen ist, dass eine Gesichtserkennungssoftware ihr Gesicht nur erkannte, wenn sie sich eine weiße Maske aufsetzte. Aufgrund dieses Erlebnisses unternahm Joy Buolamwini weitere Untersuchungen dazu und fand heraus, dass auch andere Gesichtserkennungssoftware dunklere Haut schlechter erkannte als hellere Haut und dass die Systeme bei Frauen fehleranfälliger waren als bei Männern. Diese Defizite der Software konnten auf die unausgewogenen Trainingsdaten, mit denen der Algorithmus gefüttert wurde, zurückgeführt werden. Circa zwei Drittel der Trainingsdaten bestanden aus Fotos von hellhäutigen Männern, nur ein geringer Anteil waren Frauengesichter und noch weniger waren dunkelhäutige Frauen (vgl. Kantayya 2020). Diese Beispiele zeigen deutlich, dass datenbasierte Systeme nicht automatisch neutrale oder gerechtere Entscheidungen treffen als Menschen. Die Systeme werden mit Daten trainiert, welche die bereits vorhandenen Benachteiligungen und Unterrepräsentationen weiterführen.

In ihrem Buch „Ein Algorithmus hat kein Taktgefühl – Wo künstliche Intelligenz sich irrt, warum uns das betrifft und was wir dagegen tun können“ beschreibt die Informatikprofessorin Katharina Zweig anschaulich, wie Algorithmen und datenbasierte Systeme funktionieren, was sie gut können und wo ihre Grenzen liegen (vgl. Zweig 2019). Laut Zweig können algorithmische Entscheidungssysteme keine „Lösung“ von gesellschaftlichen Diskrepanzen sein. Sie macht dies unter anderem an dem Beispiel von Amazon deutlich. Amazon arbeitete in 2014 mit einem datenbasierten Bewerbungsbewertungssystem mit dem Ziel, mögliche Diskriminierung durch Menschen im Bewerbungsprozess auszuschließen. Als Trainingsdaten wurden die Bewerbungsunterlagen der vergangenen Jahre verwendet. Das Geschlecht wurde nicht in die Trainingsdaten eingespeist. Dabei wurde allerdings vergessen, dass in der Vergangenheit vor allem Männer er-

folgreich eingestellt wurden und dass Frauen in großen Tech-Firmen unterrepräsentiert sind. So begann der Algorithmus damit, Frauen auszusortieren, wenn zum Beispiel aus ihren Unterlagen hervorging, dass sie an einem Frauen-College studiert hatten. Der Algorithmus hatte aufgrund seiner Trainingsdaten gelernt, dass dieses Merkmal nicht oft zu einer erfolgreichen Einstellung geführt hat und sortierte die Bewerbung deswegen aus (vgl. ebd. S. 212).

Die Beispiele von Joy Buolamwini und Katharina Zweig führen uns zu einem weiteren Punkt, der bei der Arbeit mit Daten oft zu wenig Aufmerksamkeit bekommt. Es handelt sich um die Leerstellen, die Vergessenen, die blinden Flecken. Die, die nicht mitgedacht, nicht mitgezählt oder schlichtweg vergessen werden. Sind keine Daten über sie vorhanden, existieren sie nicht. In der Vergangenheit bis hin in die Gegenwart betrifft dies in vielen Bereichen minorisierte Gruppen und die größte Minderheit der Welt: die Frauen. Momentan machen Frauen 49,5 % der Weltbevölkerung aus (vgl. Country Meters 2021, o.S.); trotzdem werden sie in vielen Bereichen, unter anderem in der Stadtplanung, der Medizin oder im Design, nicht (genügend) berücksichtigt. Dies kann, abgesehen von ärgerlichen Zwischenfällen im Alltag, auch schwerwiegende und lebensgefährliche Folgen haben. In ihrem Buch „Unsichtbare Frauen – Wie eine von Daten beherrschte Welt die Hälfte der Bevölkerung ignoriert“ (vgl. Criado-Perez 2020) geht Caroline Criado-Perez¹ ausführlich auf dieses Thema ein und schildert die Probleme, die durch das Phänomen der Gender-Data-Gap ausgelöst werden. Im Vorwort ihres Buches erklärt sie, was sich hinter diesem Begriff verbirgt. In der Geschichtsschreibung klafft eine große Lücke der Sichtbarkeit von Frauen. Die Frauen nehmen „weder in kultureller noch in biologischer Hinsicht viel Platz ein. Stattdessen galten männliche Lebensläufe als repräsentativ für alle Menschen“ (Criado-Perez 2020, S. 11). Dies betrifft aber nicht nur die Menschheitsgeschichte, sondern zeigt sich auch in vielen anderen Bereichen des Lebens. Diese Lücke nennt Criado-Perez die Gender-Data-Gap. Um zu verdeutlichen, wie weit die Gender-Data-Gap reicht, wird hier ein Beispiel vorgestellt. Die Schlangen, die sich in den Pausen von Veranstaltungen oder an anderen öffentlichen Orten vor Frauentoiletten bilden, sind wahrscheinlich allen schon aufgefallen, entweder weil sie daran vorbei gegangen sind oder sie selbst in der Schlange standen. Der Platz für Toiletten wird für Männer und Frauen in gleicher Quadratmeterzahl zur Verfügung gestellt. Dies erscheint gerecht und logisch. Allerdings gibt es in Männertoiletten Urinale, die weniger Platz einnehmen als Kabinen, weshalb mehr Menschen gleichzeitig auf die Toilette gehen können. Darüber hinaus benötigen Frauen beim Gang zur Toilette mehr Zeit, weil sie vermehrt von Kindern, älteren oder behinderten Personen begleitet werden. Auch die Periode oder Schwangerschaft beeinflusst die Dauer und Anzahl von Toilettenbesuchen. Bei der Planung der meisten öffentlichen Toiletten werden diese Bedürfnisse allerdings nicht berücksichtigt und so entstehen am Ende Warteschlangen vor WCs für Frauen (Criado-Perez 2020, S. 75 f).

Von immer mehr Wissenschaftler_innen wird diese scheinbar „neutrale“ und „objektive“ Sichtweise grundsätzlich in Frage gestellt (vgl. Criado-Perez 2020; D’Ignazio, Klein 2020; Roig 2021). Die Welt, wie wir sie kennen, wurde fast vollständig von weißen Männern mit einer eurozentristischen Sicht erschaffen. Da diese Sichtweise sehr tief in der Gesellschaft verankert ist, wird sie fälschlicherweise als „neutral“ und „objektiv“ wahrgenommen. Daran anschließend kann auch das Beispiel des generischen Maskulinums als „geschlechtsneutraler“ Schreibweise genannt werden.

¹Über die Autorin wird in den sozialen Medien diskutiert. Auf Grund von Aussagen aus der Vergangenheit und ihrem festhalten am binären Geschlechtersystem, wird ihr vorgeworfen Trans-Menschen nicht mit einzubeziehen.

Ein weiteres Buch, das sich mit der Datendiskrepanz auseinandersetzt, ist „Data Feminism“ der Autorinnen Catherine D’Ignazio und Lauren F. Klein (vgl. D’Ignazio, Klein 2020). Anhand von zahlreichen Beispielen aus den unterschiedlichsten Wissenschaftsbereichen zeigen die beiden Autorinnen auf, wie die Ungleichheit in den Daten entstanden ist und wie dies in Zukunft vermieden werden könnte. Entlang der sieben Prinzipien des Data Feminism, welche die Autorinnen erarbeitet haben, führen sie durch ihr Buch und die einzelnen Themenkomplexe. Im Folgenden werden die sieben Prinzipien kurz vorgestellt, da sie sehr deutlich zeigen, wie umfassend die feministische Sichtweise auf Forschungsarbeit sein kann.

1. Prinzip – Examine Power (*Die Macht untersuchen*²)

Beim ersten Prinzip geht es darum, die Wer-Fragen zu stellen. Wer profitiert von den erhobenen Daten? Wer nicht? Wer macht die Arbeit? Wer wird außen vorgelassen? Wer sammelt die Daten und wessen Daten werden gesammelt? Wessen Prioritäten werden schlussendlich in einem Produkt oder den Ergebnissen der wissenschaftlichen Arbeit berücksichtigt? Und wessen nicht? (vgl. ebd. S. 47)

2. Prinzip – Challenge Power (*Die Macht herausfordern*)

Aufbauend auf dem ersten Prinzip, wird hier danach gefragt, wie ungleiche Machtstrukturen angegangen werden können. Außerdem, wie Systeme, Studien und Forschungsergebnisse auf Ungleichheit untersucht und wie diese gerechter gestaltet werden können (vgl. ebd. S. 72).

3. Prinzip – Elevate emotion and embodiment (*Beachten von Gefühlen und Ausdrucksformen*)

Hier stellen sich die Autorinnen die Frage, wie Daten visualisiert werden. Von Statistiken und Datenvisualisierungen wird besonders angenommen, dass sie neutral und objektiv seien. Auch wird immer wieder betont, wie wichtig eine nüchterne Präsentation von Daten ist. Emotionen und Menschlichkeit haben, in der Regel, in statistischen, visuellen Darstellungen keinen Platz. Hier weisen die Autorinnen darauf hin, dass jede Datenvisualisierung aus einer bestimmten Perspektive vorgenommen wird und somit nie ganz neutral oder objektiv sein kann (vgl. ebd. S. 95 f).

4. Prinzip – Rethink binaries and hierarchies (*Binaritäten und Hierarchien überdenken*)

„Was gezählt wird, zählt“, sagte die feministische Geografin Joni Seager (vgl. ebd. S. 97). Bei Prinzip 4 regen die Autorinnen an, Klassifikationssysteme zu hinterfragen. Klassifikationen spiegeln die Werte, aber genauso die Vorurteile einer Gesellschaft wider (vgl. ebd. S. 123). Ein allgegenwärtiges Beispiel dafür sind Anmeldeformulare, in denen das Geschlecht angegeben werden muss, die Auswahl sich aber auf die weibliche und männliche Option beschränkt. In diese Formulare können sich Intersexuelle oder Non-Binäre Menschen nicht wahrheitsgetreu eintragen, werden somit auch nicht mitgezählt und in den Ergebnissen der Untersuchungen oder in offiziellen Statistiken der Länder auch nicht repräsentiert.

5. Prinzip – Embrace pluralism (*Diversität fördern*)

Unsere Gesellschaft ist vielschichtig und divers. Wenn Studien durchgeführt werden, sollte darauf geachtet werden, dass alle Betroffenen der Untersuchung *und* der Ergebnisse mit einbezogen und mitgedacht werden. Die Personen, die sich am besten mit der untersuchten Angelegenheit

²Die kursiv geschriebenen deutschen Überschriften sind eigene Übersetzungen.

auskennen, sind die Personen deren Angelegenheit untersucht wird. Die lokale Zusammenarbeit soll dabei berücksichtigt und gefördert werden, genauso wie die Diversität in der Forschung selbst (vgl. ebd. S. 147 f).

6. Prinzip – Consider context (*Den Kontext beachten*)

Die Autorinnen weisen bei diesem Prinzip darauf hin, dass Daten nicht neutral und objektiv sind, sondern immer in einem bestimmten Kontext entstehen und auch in diesem gelesen werden sollten. Zahlen können nicht für sich selbst sprechen. Der Kontext sollte stets miteinbezogen, dargestellt und sichtbar gemacht werden. Außerdem sollte die Frage danach gestellt werden, wie der ursprüngliche Kontext war, wenn Daten nachgenutzt werden (vgl. ebd. S. 171 f).

7. Prinzip – Make labor visible (*Die Arbeit sichtbar machen*)

Im siebten und somit letzten Prinzip des Data Feminism, erinnern die Autorinnen daran, dass fertiggestellte Arbeit, die Arbeit vieler ist. Sie regen an, sich die Fragen zu stellen: Durch wie viele Hände geht ein Produkt/eine Untersuchung bis es/sie fertig ist? Die Arbeit von welchen Menschen wird womöglich vergessen/nicht gezeigt? Die Arbeit Anderer sichtbar zu machen, bedeutet andere Menschen zu unterstützen, in den Fokus zu rücken und ihren Anteil an der Arbeit zu würdigen (vgl. ebd. S. 200 f).

Zusammenfassend arbeiten die sieben Prinzipien des Data Feminism von Catherine D'Ignazio und Lauren F. Klein einen breiten Rahmen aus, wie Forschung gerechter werden kann. Das Buch ist Open Access erhältlich³.

Was hat das nun alles mit der Bibliotheks- und Informationswissenschaft zu tun?

Nun, unsere Disziplin ist darauf spezialisiert, mit Informationen zu arbeiten, die mittlerweile meistens digital sind. Informationen sind unser Forschungsgegenstand, unser Hauptaugenmerk. Ob wir nun untersuchen, wie Menschen, Informationen und Technologien interagieren oder wie Informationen gefunden, aufbereitet und nutzbar gemacht werden können. Oder ob wir über die Relevanz von Informationssystemen und den Aufbau von Datenbanken nachdenken. Bis hin zu der Nutzung von Klassifikationen und Bibliothekskatalogen in der eigenen Forschung, aber auch als Endprodukt für Nutzer_innen. Seit jeher sind Bibliotheken Meisterinnen der Katalogisierung und der Klassifikationen. Diesen Systemen liegen Wertvorstellungen zugrunde, und zwar nicht irgendwelche, sondern die Werte, die die Erschaffenden dieser Systeme hatten. Wie verschiedene Klassifikationssysteme zeigen (z. B. die Dewey-Dezimalklassifikation), repräsentieren sie eine gewisse Weltanschauung und verweisen auf den Zeitgeist, in welchem diese Systeme erstellt wurden. Erneuerungen und Anpassungen an die sich verändernden Werte werden zwar vorgenommen, meistens aber sehr verzögert und nicht umfassend. Zum Beispiel wurde erst in der 22. Fassung der Dewey-Dezimalklassifikation von 2006 der Begriff „rassisch“ geändert, sowie die Ausschließung der Notationen für Rassen vorgenommen (vgl. Chan, Mitchell 2006, S. 186).

Abgesehen von den ethischen Fragen, die sich unsere Disziplin in Bezug auf Daten und Informationen stellen muss, sollte auch nicht vergessen werden, dass wir uns in einem System mit Machtstrukturen bewegen. Wir sollten uns vergegenwärtigen, dass es auch im Kontext des Bibliothekswesens und der Bibliotheks- und Informationswissenschaft Personen oder Gruppen gibt, die wenig bis keine Repräsentation erfahren und diese in Zukunft in unsere Forschung und

³data-feminism.mitpress.mit.edu/

in die Entwicklung von neuen Konzepten in Bibliotheken mit einbeziehen (Stichwort: Diversity Management).

Abschließend kann gesagt werden, dass die feministische oder die ganzheitliche Sicht auf die Arbeit mit Daten im ersten Moment vielleicht komplizierter und aufwändiger erscheint als altbewährte Strategien, allerdings die so erarbeitete Forschung und Konzepte umfassender, gerechter und repräsentativer sein werden als bisher. Und dies ist doch ein erstrebenswertes Ziel.

Literaturnachweise:

Chan, Lois Mai; Mitchell, Joan S.: *Dewey Dezimalklassifikation – Theorie und Praxis. Lehrbuch zur DDC 22*. München, 2006.

Country Meters (abgerufen am 05.06.21), <https://countrymeters.info/de/World>.

Criado-Perez, Caroline: *Unsichtbare Frauen – Wie eine von Daten beherrschte Welt die Hälfte der Bevölkerung ignoriert*. München, 2020.

D'Ignazio, Catherine; Klein, Lauren F.: *Data Feminism*. Massachusetts, 2020, <https://data-feminism.mitpress.mit.edu/>.

Kantayya, Shalini: *Coded Bias*. United States: 7th Empire Media, 2020.

O'Neil, Cathy: *Weapons of Math Destruction – How Big Data increases Inequality and threatens Democracy*. London, 2017.

Roig, Emilia: *Why we matter – Das Ende der Unterdrückung*. Berlin, 2021.

Zweig, Katharina: *Ein Algorithmus hat kein Taktgefühl – Wo künstliche Intelligenz sich irrt, warum uns das betrifft und was wir dagegen tun können*. München, 2019.

Sara Juen , *1983, Sortimentsbuchhändlerin, von 2016–2019 Bachelorstudium in Bibliotheks- und Informationswissenschaft an der Humboldt Universität zu Berlin, seit Oktober 2019 Masterstudentin für Informationswissenschaft (HU). Seit 2021 Mitglied der LIBREAS Redaktion. ORCID: <https://orcid.org/0000-0003-0725-8592>